

MÁSTER EN BIG DATA, DATA SCIENCE E INTELIGENCIA ARTIFICIAL

Minería de Datos y Modelización Predictiva

ANÁLISIS Y PREDICCIÓN DE SERIES TEMPORALES

Ventas minoristas mensuales en EE.UU. (RSXFSN)

Eloy Celaya López

Junio 2026

Índice

1. Introducción.....	3
2. Representación gráfica y descomposición.....	3
2.1 Visualización de la serie original	3
2.2 Descomposición estacional.....	4
2.3 Coeficientes estacionales.....	6
3. División train / test.....	7
4. Modelo de suavizado exponencial Holt-Winters.....	8
4.1 Selección del modelo	8
4.2 Parámetros estimados	9
4.3 Expresión del modelo.....	9
5. Identificación y ajuste del modelo SARIMA.....	10
5.1 Transformación logarítmica y estacionariedad	10
5.2 Diferenciación regular ($d = 1$) y tests de estacionariedad	11
5.3 Diferenciación estacional ($D = 1$) y correlogramas finales.....	12
5.4 Selección automática con auto_arima.....	13
5.5 Ajuste del modelo y comprobación de idoneidad	13
6. Expresión algebraica del modelo ajustado	14
7. Predicciones e intervalos de confianza	15
8. Comparación de métodos y conclusiones	16
8.1 Comparación numérica.....	16
8.2 Conclusiones	17

1. Introducción

La serie analizada corresponde a las **ventas minoristas mensuales en Estados Unidos**, identificada con el código **RSXFSN** (Retail Sales, Not Seasonally Adjusted), publicada por el U.S. Census Bureau y disponible en la base de datos FRED (Federal Reserve Economic Data).

La serie recoge el volumen de ventas al por menor en **millones de dólares corrientes**, con frecuencia mensual, desde enero de 2012 hasta diciembre de 2025, lo que supone un total de **168 observaciones**. Se trata de una serie temporal ya que cada observación representa la evolución de la variable a lo largo de una unidad de tiempo, y el orden de las observaciones es fundamental para el análisis.

El objetivo del estudio es triple:

- Identificar la estructura de la serie: tendencia, estacionalidad y componente irregular.
- Ajustar y comparar dos familias de modelos de predicción: suavizado exponencial (Holt-Winters) y modelos SARIMA.
- Evaluar la capacidad predictiva de ambos métodos sobre el último año de la serie (2025), reservado como conjunto de test.


2. Representación gráfica y descomposición

2.1 Visualización de la serie original

La representación temporal de las ventas minoristas muestra una evolución claramente creciente entre 2012 y 2025. La serie presenta una tendencia ascendente sostenida, interrumpida únicamente por una caída abrupta en 2020, coherente con el impacto económico inicial de la pandemia de COVID-19. Tras este shock, se observa una recuperación rápida y un cambio de nivel, con valores posteriores superiores a los registrados antes de 2020.

Además de la tendencia, el gráfico evidencia una estacionalidad anual muy marcada. El patrón se repite de forma sistemática: los valores mínimos suelen concentrarse en enero y febrero, mientras que diciembre registra el máximo anual, asociado al incremento del consumo durante el periodo navideño. Esta regularidad justifica incorporar una componente estacional de periodo 12 en los modelos posteriores.

También se aprecia que la amplitud de las oscilaciones estacionales aumenta conforme crece el nivel de la serie. Es decir, las diferencias entre meses de baja y alta venta son mayores en los últimos años que al inicio del periodo. Este comportamiento sugiere una estructura multiplicativa, ya que la componente estacional parece actuar de forma proporcional al nivel de ventas y no como una variación absoluta constante.




2.2 Descomposición estacional

Una serie temporal puede descomponerse en sus componentes parciales. La descomposición **multiplicativa** expresa la serie como el producto de tres componentes:

$$y_t = T_t * S_t * Z_t$$


donde T_t es la tendencia, S_t el componente estacional y Z_t el componente irregular o aleatorio. La componente cíclica se incluye dentro de la tendencia al no presentar períodos claramente identificables. Se elige el esquema multiplicativo frente al aditivo porque la **variabilidad de la serie crece con el nivel**: si la variabilidad fuera constante a lo largo del tiempo (homocedasticidad), sería más apropiado el modelo aditivo.

Se aplica la descomposición con `seasonal_decompose` (período = 12).



La descomposición permite visualizar por separado las tres series y analizar cada componente:

- La tendencia es creciente y prácticamente continua. Se aprecian dos fases: crecimiento moderado 2012-2019 y crecimiento acelerado 2021-2025 tras la recuperación post-COVID.
- El componente estacional es muy regular y estable a lo largo de todos los años, con un patrón idéntico año tras año (coeficiente $\gamma \approx 0$ en el modelo de suavizado).
- El residuo oscila en torno a 1 con escasa variabilidad durante todo el período, salvo el outlier de 2020. La caída brusca en el residuo en los meses de marzo-abril 2020 (coeficiente $\sim 0,7$) y la posterior subida en mayo-junio 2020 ($\sim 1,15$) reflejan el shock COVID y la recuperación, que ningún modelo puede anticipar con los datos históricos disponibles.




El gráfico anterior muestra la **serie ajustada estacionalmente** (serie original / componente estacional), que elimina el efecto estacional y permite ver mejor la tendencia. La serie ajustada confirma que la tendencia es claramente creciente sin el ruido estacional.


2.3 Coeficientes estacionales

Los coeficientes estacionales medios por mes, obtenidos de la descomposición multiplicativa, son:

Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
0.907	0.887	1.012	0.982	1.047	1.010	1.014	1.032	0.963	0.997	1.017	1.132

El mes con mayor coeficiente es **diciembre (1.132)**, con ventas un 13.2% superiores a la media anual, reflejo de la campaña navideña. El mes con menor coeficiente es **febrero (0.887)**, un 11.3% por debajo de la media. Un coeficiente mayor que 1 indica que ese mes se vende por encima del nivel medio anual; uno menor que 1, por debajo. El patrón es muy consistente a lo largo de todos los años.





El seasonal plot permite comparar el perfil mensual de ventas entre años. La forma de las curvas es similar en la mayoría de ejercicios: caída al inicio del año, recuperación progresiva durante la primavera y verano, y máximo en diciembre. Esta superposición visual confirma que la estacionalidad es estable y recurrente.

No obstante, también se observa que las curvas correspondientes a los años más recientes se sitúan por encima de las primeras, lo que refleja el crecimiento estructural de la serie. Por tanto, el gráfico muestra simultáneamente dos características relevantes: un patrón intraanual persistente y una tendencia creciente entre años.

3. División train / test

Para evaluar la capacidad predictiva de los modelos, se reserva el **último periodo completo** (12 observaciones, correspondientes al año 2025) como conjunto de test. Los modelos se ajustan exclusivamente sobre el conjunto de entrenamiento, de modo que la evaluación es **imparcial**: los datos de test no han influido en absoluto en la estimación de los parámetros.


Conjunto	Observaciones	Período
Train	156	2012-01 a 2024-12
Test	12	2025-01 a 2025-12

La partición train/test se realiza respetando el orden temporal de la serie. En series temporales no es adecuado aplicar una división aleatoria, ya que rompería la dependencia cronológica entre observaciones y produciría una evaluación artificialmente optimista.

Se reserva el último año completo, 2025, como conjunto de test. De este modo, el modelo se entrena únicamente con información disponible hasta diciembre de 2024 y se evalúa sobre un horizonte futuro realista de 12 meses. Esta elección es coherente con el objetivo del trabajo:

predecir un año completo de ventas mensuales y comparar la precisión de los modelos en un escenario fuera de muestra.

El gráfico de train/test permite comprobar visualmente que el conjunto de test mantiene el mismo patrón estacional de la serie, con valores relativamente bajos al inicio del año y un máximo en diciembre. Esto es importante porque obliga al modelo a reproducir tanto la tendencia como la estacionalidad anual, no solo el nivel medio de la serie.



4. Modelo de suavizado exponencial Holt-Winters

4.1 Selección del modelo

Se comparan tres variantes del modelo Holt-Winters según la combinación de tendencia y estacionalidad (aditiva o multiplicativa), evaluadas por **AIC** sobre el conjunto de entrenamiento y por **RMSE** sobre el conjunto de test:

Modelo	AIC	RMSE (test)	MAE (test)
add-add	2982.9	20.164	17.650
add-mul	2966.8	9.000	7.749
mul-mul	2965.4	11.320	9.381

Entre las distintas configuraciones evaluadas, se selecciona el modelo con tendencia multiplicativa y estacionalidad multiplicativa. Este modelo presenta el menor valor de AIC, lo que indica el mejor equilibrio entre calidad de ajuste y complejidad entre las alternativas consideradas.

Además, la naturaleza de la serie respalda esta elección. Tanto la tendencia como la amplitud de las fluctuaciones estacionales aumentan con el nivel de ventas, comportamiento característico de procesos multiplicativos. Por ello, esta especificación resulta consistente con la estructura observada en los datos.

4.2 Parámetros estimados

Los parámetros óptimos del modelo Holt-Winters mul-mul, estimados por mínimos cuadrados, son:

Parámetro	Valor	Interpretación
α (nivel)	0.507	Actualización moderada del nivel ante nuevas observaciones
β (tendencia)	0.000	Tendencia completamente estable; no se actualiza con el tiempo
γ (estacionalidad)	0.000	Patrón estacional fijo; no cambia a lo largo del periodo

Los valores $\beta = \gamma = 0$ indican que tanto la tendencia de crecimiento como el patrón estacional son muy estables a lo largo del periodo analizado, lo que justifica la elección de un modelo parsimonioso.

4.3 Expresión del modelo

El modelo Holt-Winters **completamente multiplicativo** (tendencia multiplicativa $\times$ estacionalidad multiplicativa) viene dado por:

$$\hat{y}(t+h) = (L_t \cdot T_t^h) \cdot S(t+h-m)$$


con las ecuaciones de actualización:

$$L_t = \alpha \cdot (y_t / S(t-m)) + (1-\alpha) \cdot L(t-1) \cdot T(t-1)$$

$$T_t = \beta \cdot (L_t / L(t-1)) + (1-\beta) \cdot T(t-1)$$

$$S_t = \gamma \cdot (y_t / L_t) + (1-\gamma) \cdot S(t-m)$$

con $m = 12$ (período estacional mensual), $\alpha = 0.507$, $\beta = 0.000$ y $\gamma = 0.000$. Las predicciones se obtienen por proyección directa de los componentes estimados.



En el gráfico de predicción se observa que el modelo reproduce adecuadamente tanto la tendencia creciente como el patrón estacional anual de la serie. Las predicciones mantienen la sucesión de

mínimos al inicio del año y máximos en diciembre, reflejando correctamente la estructura temporal observada durante el periodo de entrenamiento.


Las mayores discrepancias se concentran en algunos meses concretos, especialmente en los picos de demanda, donde la variabilidad es más elevada. No obstante, el modelo sigue de forma razonable la evolución general de las ventas y captura la dinámica principal de la serie.

5. Identificación y ajuste del modelo SARIMA


Para el modelado ARIMA se sigue la **metodología Box-Jenkins**, que consta de cuatro pasos: (1) identificación del modelo (selección de d , D , p , q , P , Q), (2) estimación de parámetros, (3) validación del ajuste (diagnóstico de residuos) y (4) cálculo de predicciones.

5.1 Transformación logarítmica y estacionariedad

Dado que la varianza de la serie crece con el nivel (heterocedasticidad), se aplica la **transformación logarítmica** para estabilizarla. Esta transformación es un caso particular de la familia Box-Cox con $\lambda = 0$, que permite homogeneizar la varianza sin alterar la estructura temporal de la serie. Sobre la serie log se analiza la estacionariedad.



La ACF de la serie log muestra un decaimiento muy lento hacia cero, indicando claramente la presencia de una raíz unitaria (no estacionariedad en media).




5.2 Diferenciación regular ($d = 1$) y tests de estacionariedad

Se aplica una diferenciación de orden 1 para eliminar la tendencia. La estacionariedad de la serie resultante se contrasta mediante los tests de Dickey-Fuller Aumentado (ADF) y KPSS:

Test	Estadístico / p-valor	Conclusión
ADF (H_0 : raíz unitaria)	$p = 0.023$	Rechaza $H_0 \rightarrow$ estacionaria
KPSS (H_0 : estacionaria)	$p = 0.100$	No rechaza $H_0 \rightarrow$ confirma

Conclusión: $d = 1$. La diferenciación de orden 1 es suficiente para eliminar la tendencia. El test ADF rechaza la hipótesis nula de raíz unitaria ($p = 0.023 < 0.05$) y el KPSS no rechaza la estacionariedad ($p = 0.10 > 0.05$).




5.3 Diferenciación estacional (D = 1) y correlogramas finales


Aunque la diferenciación regular elimina la tendencia, la serie diferenciada sigue mostrando un patrón estacional visible. Se aplica una diferenciación adicional de orden 12 para eliminar la estacionalidad mediante el operador:

$$\nabla_{12} X_t = X_t - X_{t-12} = (1 - B^{12}) X_t$$

Tras la doble diferenciación, el test ADF confirma estacionariedad ($p = 0.0008$). Por tanto, $D = 1$.



El análisis de los correlogramas de la serie doblemente diferenciada permite identificar el orden del modelo:



Para la identificación de los órdenes se aplica la tabla de patrones teóricos:

Proceso	ACF	PACF
MA(q)	Corte brusco después del retardo q	Decrecimiento exponencial o sinusoidal
AR(p)	Decrecimiento exponencial o sinusoidal	Corte brusco después del retardo p

- ACF: corte significativo en el retardo 1 $\rightarrow q = 1$ (componente MA). Corte en el retardo 12 $\rightarrow Q = 1$ (componente MA estacional).
- PACF: decaimiento progresivo $\rightarrow$ confirma componente MA, no AR.

Los correlogramas muestran que, tras aplicar las diferenciaciones regular y estacional, la mayor parte de la estructura temporal ha sido eliminada. La ACF presenta un pico significativo en el primer retardo y otro en el retardo estacional 12, mientras que la PACF no muestra cortes bruscos claros. Este patrón es consistente con la presencia de componentes MA tanto regulares como estacionales.

Modelo candidato inicial: **SARIMA(0,1,1)(0,1,1)[12]**. Se confirma y optimiza con *auto_arima*.

5.4 Selección automática con *auto_arima*

La función *auto_arima* (criterio AIC, búsqueda escalonada) explora 41 modelos candidatos. El modelo con menor AIC es:

`SARIMA(0,1,2)(2,1,1)[12]` AIC = -584.9

5.5 Ajuste del modelo y comprobación de idoneidad

El modelo **SARIMA(0,1,2)(2,1,1)[12]** se ajusta con SARIMAX sobre la serie logarítmica del conjunto de entrenamiento. Los resultados son:


Parámetro	Estimación	Std. Error	z	p-valor
ma.L1	-0.343	0.052	-6.56	0.000 ***
ma.L2	-0.240	0.063	-3.83	0.000 ***
ar.S.L12	-0.137	0.148	-0.92	0.356
ar.S.L24	-0.184	0.152	-1.21	0.226
ma.S.L12	-0.724	0.152	-4.75	0.000 ***
sigma ² (varianza)	0.0009	8.64e-05	10.74	0.000 ***

AIC	BIC	Ljung-Box p	Obs.
-471.8	-455.2	0.76 (lag 1)	156

Los componentes MA regular (ma.L1, ma.L2) y el MA estacional (ma.S.L12) son **altamente significativos**. Los términos AR estacionales (ar.S.L12, ar.S.L24) no son individualmente significativos, aunque su inclusión está justificada por el criterio AIC global.

El test de **Ljung-Box** ($p = 0.76 \gg 0.05$) confirma que los residuos no presentan autocorrelación significativa: se comportan como **ruido blanco**, lo que es una condición necesaria para que el modelo sea adecuado.

El análisis gráfico de los residuos refuerza la validez del modelo. Los residuos estandarizados oscilan alrededor de cero sin patrones sistemáticos aparentes, el histograma presenta una forma aproximadamente normal y el gráfico Q-Q muestra una alineación razonable con la distribución teórica. Asimismo, el correlograma de residuos no evidencia autocorrelaciones significativas, lo que resulta consistente con el resultado obtenido mediante el test de Ljung-Box.



6. Expresión algebraica del modelo ajustado

La forma general de un modelo SARIMA(p,d,q)(P,D,Q)[m] según la notación del curso es:

$$(1 - \phi_1 B^s - \dots - \phi_p B^p) (1 - \Phi_1 B^S - \dots - \Phi_P B^P) (1 - B)^d (1 - B)^D X_t = (1 - \theta_1 B^s - \dots - \theta_q B^q) (1 - \Theta_1 B^S - \dots - \Theta_Q B^Q) Z_t$$

Para el modelo seleccionado **SARIMA(0,1,2)(2,1,1)[12]**, aplicado sobre la serie logarítmica, la expresión es:

$$(1 - \phi_1 B^{12} - \phi_2 B^{24}) (1 - B) (1 - B^{12}) \ln(y_t) = (1 + \theta_1 B + \theta_2 B^2) (1 + \Theta_1 B^{12}) \varepsilon_t$$

Sustituyendo los parámetros estimados:

$$(1 + 0.137 B^{12} + 0.184 B^{24}) (1 - B) (1 - B^{12}) \ln(y_t) = (1 - 0.343 B - 0.240 B^2) (1 - 0.724 B^{12}) \varepsilon_t$$

Parámetro	Símbolo	Interpretación
ma.L1	$\hat{\theta}_1 = -0.343$	Componente MA regular de orden 1: significativo


ma.L2	$\hat{\theta}_2 = -0.240$	Componente MA regular de orden 2: significativo
ar.S.L12	$\hat{\phi}_1 = -0.137$	AR estacional lag 12: no significativo (p=0.356)
ar.S.L24	$\hat{\phi}_2 = -0.184$	AR estacional lag 24: no significativo (p=0.226)
ma.S.L12	$\hat{\theta}_1 = -0.724$	MA estacional lag 12: muy significativo, capta el ciclo anual

Los términos AR estacionales no son individualmente significativos, pero su inclusión está justificada por el mejor AIC global del modelo.

7. Predicciones e intervalos de confianza

Las predicciones se calculan para los **12 meses del año 2025**, que constituyen el conjunto de test. El modelo SARIMA predice en escala logarítmica y los resultados se transforman a escala original mediante la función exponencial. Los intervalos de confianza al 95% se obtienen directamente del modelo.

El gráfico muestra que el modelo reproduce adecuadamente tanto la tendencia como la estacionalidad anual observadas en la serie. Las predicciones siguen de cerca la evolución real durante 2025 y reflejan correctamente la sucesión de mínimos a comienzos de año y máximos al final del ejercicio. Además, la amplitud de los intervalos de confianza aumenta ligeramente conforme se avanza en el horizonte de predicción, comportamiento habitual en modelos de series temporales debido a la acumulación de incertidumbre.



Fecha	Real	Pred. SARIMA	IC inf. 95%	IC sup. 95%
2025-01	566662	563784	531090	598491
2025-02	543970	553315	515142	594316

2025-03	624954	638611	592046	688838
2025-04	623756	621233	573635	672781
2025-05	647306	664996	611709	722926
2025-06	616031	649597	595370	708763
2025-07	644493	653331	596701	715336
2025-08	640803	661920	602512	727185
2025-09	611277	623879	566043	687626
2025-10	642315	651207	588981	720008
2025-11	640201	664859	599496	737348
2025-12	716924	733253	659210	815614


Todos los valores reales observados en 2025 quedan dentro del intervalo de confianza al 95% del modelo SARIMA, lo que confirma la validez y calibración del ajuste.

8. Comparación de métodos y conclusiones

8.1 Comparación numérica

Método	RMSE	MAE	MAPE	IC 95% válido
Holt-Winters mul-mul (*)	11.320	9.381	1,50%	No aplica
SARIMA(0,1,2)(2,1,1)[12]	16.745	14.341	2,27%	Sí (todos dentro)

(*) Mejor método en términos de precisión predictiva sobre el test. Cifras en millones de dólares.



8.2 Conclusiones

- La serie RSXFSN es una serie temporal no estacionaria con estacionalidad multiplicativa muy marcada (pico en diciembre, +13,2%) y tendencia creciente sostenida. La varianza crece con el nivel (heterocedasticidad), lo que justifica aplicar logaritmo antes del modelado SARIMA y elegir el esquema multiplicativo en Holt-Winters.
- El modelo Holt-Winters mul-mul resulta más preciso sobre el conjunto de test: RMSE = 11.320, MAE = 9.381 y MAPE = 1,50%. Sus parámetros $\beta = \gamma = 0$ revelan que tanto la tendencia como la estacionalidad son muy estables a lo largo del periodo analizado, lo que favorece modelos parsimoniosos. Cabe destacar que el modelo add-mul, aunque tiene un AIC ligeramente superior (2966,8 vs 2965,4), presenta un RMSE inferior (9.000) sobre el test, por lo que también sería una opción válida si el criterio principal es la precisión predictiva.
- El modelo SARIMA(0,1,2)(2,1,1)[12] aporta una base estadística más rigurosa: MAPE = 2,27%, y permite cuantificar la incertidumbre mediante intervalos de confianza al 95%. Todos los valores reales observados en 2025 quedan dentro de dichos intervalos, lo que confirma la correcta calibración del modelo. Su mayor RMSE (16.745) refleja una menor precisión predictiva sobre el conjunto de test respecto al modelo Holt-Winters, aunque ofrece ventajas importantes desde el punto de vista estadístico, como la validación formal de supuestos y la construcción de intervalos de confianza.
- Ambos modelos confirman que la estacionalidad de período 12 es el factor dominante de la serie, que la tendencia es creciente y estable, y que el impacto COVID actúa como un outlier aislado en el componente irregular.
- La comparación visual de las predicciones confirma los resultados numéricos obtenidos mediante RMSE y MAE. Ambos modelos siguen correctamente la trayectoria de la serie durante 2025, aunque Holt-Winters reproduce con mayor precisión los cambios de nivel y las fluctuaciones estacionales observadas. Las diferencias son especialmente visibles en los meses de mayor volumen de ventas, donde SARIMA tiende a suavizar ligeramente las variaciones.
- Los resultados obtenidos muestran que la evolución de las ventas puede describirse adecuadamente mediante una tendencia creciente y una estacionalidad anual estable. En este contexto, Holt-Winters es el método que proporciona la mejor precisión predictiva, mientras que SARIMA ofrece una modelización más completa desde el punto de vista estadístico.